CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

1.1. Kho dữ liệu và PostgreSQL

Khác với các hệ thống xử lý giao dịch trực tuyến (OLTP) vốn được tối ưu hóa cho việc ghi nhận dữ liệu hàng ngày, kho dữ liệu (data warehouse) làm nhiệm vụ tích hợp dữ liệu từ nhiều nguồn thành một cấu trúc thống nhất, chuyên biệt để phục vụ truy vấn và phân tích (Kimball và Ross, 2013). Dữ liệu được đưa vào kho thông qua quy trình ETL (Trích xuất - Biến đổi - Nạp). Trong đó, khu vực trung gian (staging) sẽ lưu trữ dữ liệu thô nguyên bản nhằm mục đích đối chiếu và hỗ trợ chạy lại quy trình khi có sự cố.

Mô hình chiều là phương pháp thiết kế kho dữ liệu phổ biến, bao gồm các bảng sự kiện (fact) lưu trữ các phép đo định lượng (số lượng, doanh thu...) và bảng chiều (dimension) chứa các thuộc tính mô tả (thông tin khách hàng, sản phẩm, thời gian). Thiết kế thường bắt đầu bằng việc xác định độ mịn (grain) của bảng sự kiện. Trong đó, mô hình sao (star schema) – kết nối trực tiếp một bảng sự kiện trung tâm với các bảng chiều xung quanh – được đánh giá cao nhờ cấu trúc phi chuẩn hóa, giúp truy vấn nhanh và đặc biệt tương thích với các công cụ BI như Power BI.

PostgreSQL là hệ quản trị cơ sở dữ liệu quan hệ – đối tượng mã nguồn mở, tuân thủ chặt chẽ mô hình của Codd (1970). Hệ thống này đảm bảo tính toàn vẹn ACID và hỗ trợ xử lý đồng thời mức độ cao qua cơ chế MVCC. Để phục vụ phân tích dữ liệu lớn, PostgreSQL cung cấp nhiều tính năng mạnh mẽ như biểu thức bảng chung (CTE), hàm cửa sổ (window functions), mệnh đề lọc điều kiện, hàm tính phân vị, cùng hệ thống chỉ mục B-tree tối ưu hóa tốc độ truy vấn.

1.2. Khám phá và tiền xử lý dữ liệu

Phân tích dữ liệu khám phá (EDA) là bước đánh giá chất lượng bộ dữ liệu dựa trên bốn tiêu chí: tính đầy đủ, tính hợp lệ, tính duy nhất và sự nhất quán. Dựa trên kết quả EDA, các kỹ thuật tiền xử lý được áp dụng bao gồm:

- **Xử lý dữ liệu thiếu:** Tùy thuộc vào cơ chế thiếu sót của dữ liệu (MCAR, MAR, MNAR) để quyết định xóa bỏ, điền khuyết hay tách thành luồng riêng. Đối với các trường dữ liệu định danh như mã khách hàng, việc tự động điền khuyết sẽ làm sai lệch thực tế, do đó giải pháp tối ưu là tách các bản ghi này ra khỏi nhóm phân tích hành vi cá nhân.
- **Xử lý ngoại lai:** Phương pháp khoảng tứ phân vị (IQR) truyền thống thường gán cờ sai cho các đơn hàng bán sỉ trong tập dữ liệu bán lẻ có độ lệch phải cao. Giải pháp thực tiễn hơn là kết hợp luật nghiệp vụ để loại bỏ dữ liệu lỗi/phi giao dịch,

đồng thời giữ lại các giao dịch lớn hợp lệ và làm mượt độ lệch bằng phép biến đổi logarit hoặc kỹ thuật winsorization (cắt biên giá trị ở các mốc phân vị cao).

- **Mã hóa biến:** Biến phân loại có ít giá trị thường được mã hóa dạng one-hot, trong khi các nhóm hiếm gặp có thể gộp chung thành nhãn "Other". Đối với biến có không gian mẫu lớn như mã sản phẩm, cách tốt nhất là tổng hợp chúng thành các đặc trưng hành vi cấp độ khách hàng. Với dữ liệu văn bản, thuật toán TF-IDF thường được sử dụng để đánh giá trọng số và mức độ quan trọng của từ vựng.
- **Chuẩn hóa:** Kỹ thuật chuẩn hóa (như z-score) là bắt buộc đối với các thuật toán tối ưu hóa dựa trên khoảng cách (K-Means, Hồi quy logistic), nhưng có thể bỏ qua khi sử dụng các mô hình dựa trên cây quyết định.
- **Chống rò rỉ dữ liệu (Data leakage):** Để tránh việc thông tin từ tương lai lọt vào tập huấn luyện làm sai lệch kết quả đánh giá, dữ liệu cần được chia tách nghiêm ngặt theo trục thời gian, và các tham số tiền xử lý chỉ được phép học (fit) trên tập huấn luyện.

1.3. Phân khúc khách hàng

Mô hình RFM (Hughes, 1994) là phương pháp kinh điển giúp mô tả khách hàng qua ba khía cạnh: Recency (thời gian từ lần mua cuối), Frequency (tần suất mua) và Monetary (tổng mức chi tiêu). Chen, Sain và Guo (2012) từng chứng minh tính hiệu quả của việc kết hợp RFM với khai phá dữ liệu trên các tập dữ liệu bán lẻ thương mại điện tử.

Để phân cụm khách hàng, thuật toán K-Means (MacQueen, 1967) thường được sử dụng nhằm gom nhóm các điểm dữ liệu sao cho phương sai nội bộ cụm là nhỏ nhất. Do tính toán dựa trên khoảng cách Euclid, dữ liệu RFM đầu vào cần được chuẩn hóa kỹ lưỡng. Số lượng cụm tối ưu thường được xác định qua phương pháp khuỷu tay (elbow) và hệ số độ bóng (silhouette), kết hợp chặt chẽ với tính ứng dụng trong thực tế kinh doanh.

Bên cạnh đó, sự biến động hành vi của khách hàng theo thời gian được theo dõi bằng cách lấy "ảnh chụp" (snapshot) RFM định kỳ. Tính ổn định của các phân khúc này có thể được đo lường thông qua ma trận chuyển dịch và chỉ số Rand điều chỉnh (ARI; Hubert và Arabie, 1985).

1.4. Bài toán rời bỏ trong bối cảnh không có hợp đồng

Khác với các ngành dịch vụ đăng ký gói cước, khách hàng bán lẻ trực tuyến thường ngừng mua sắm một cách thầm lặng. Việc "rời bỏ" (churn) trở thành một trạng thái ẩn, chỉ có thể phỏng đoán qua sự vắng mặt kéo dài. Dù các mô hình xác suất như Pareto/NBD hay BG/NBD đã được phát triển để giải quyết vấn đề này, việc chuyển đổi

sang hướng tiếp cận Học máy có giám sát (định nghĩa nhãn theo thời gian) mang lại sự linh hoạt cao hơn khi cần kết hợp nhiều đặc trưng đa chiều.

Trong phương pháp này, tại một thời điểm cắt (T), lịch sử giao dịch trước T được dùng để trích xuất đặc trưng, còn khoảng thời gian (T, T + H] đóng vai trò là cửa sổ hiệu năng để gắn nhãn. Khách hàng được xem là rời bỏ (Y=1) nếu không phát sinh giao dịch nào trong H ngày. Việc xác định ngưỡng H đòi hỏi sự cân nhắc kỹ lưỡng: H quá nhỏ sẽ gây ra nhiều báo động giả, trong khi H quá lớn lại khiến việc cảnh báo trở nên muộn màng. Ngưỡng H thường được ấn định dựa trên các mốc phân vị của khoảng cách giữa hai lần mua liên tiếp của khách hàng. Ngoài ra, bài toán cần giải quyết triệt để các rào cản như: dữ liệu bị cắt cụt, kiểm duyệt phải, yếu tố mùa vụ và loại trừ các đơn hàng bị hoàn hủy.

1.5. Mô hình học máy và đánh giá

Bản chất của bài toán là phân loại nhị phân, trong đó mô hình xuất ra xác suất rời bỏ nhằm giúp doanh nghiệp xếp hạng mức độ rủi ro của từng khách hàng.

Mô hình	Ưu điểm	Hạn chế	Vai trò trong dự án
Luật Recency	Dễ triển khai, không cần huấn luyện.	Góc nhìn phiến diện, chỉ dựa vào 1 biến.	Mô hình cơ sở (Baseline 1)
Hồi quy Logistic	Nhanh, nhẹ, dễ giải thích diễn biến của đặc trưng.	Bị giới hạn ở các mối quan hệ tuyến tính.	Mô hình cơ sở (Baseline 2)
Random Forest	Xử lý tốt các mối quan hệ phi tuyến, bền vững với dữ liệu nhiễu.	Khó diễn giải chi tiết cho từng dự đoán (hộp đen).	Mô hình phân loại chính
Luật Recency	Dễ triển khai, không cần huấn luyện.	Góc nhìn phiến diện, chỉ dựa vào 1 biến.	Mô hình phân loại chính

Hiệu năng của các thuật toán phức tạp sẽ được đối chiếu với các mô hình cơ sở (baseline) để chứng minh giá trị thực tiễn. Đánh giá mô hình sử dụng các thang đo như

Precision, Recall, F1-score, ROC-AUC. Trong bối cảnh nhãn dữ liệu mất cân bằng, chỉ số PR-AUC được ưu tiên do độ nhạy bén cao hơn (Saito và Rehmsmeier, 2015). Để định hướng trực tiếp cho các chiến dịch Marketing (ví dụ: khoanh vùng 500 khách hàng rủi ro cao nhất), các chỉ số như Precision@K, Lift@K và điểm hiệu chỉnh Brier sẽ được tích hợp để đánh giá độ tin cậy của xác suất đầu ra.

Về phương pháp huấn luyện, do một khách hàng có thể lặp lại ở nhiều chu kỳ thời gian, kỹ thuật kiểm định chéo K-Fold thông thường sẽ gây rò rỉ dữ liệu. Giải pháp thay thế là chia tách tập dữ liệu tiến lên theo thời gian (temporal split). Việc đánh giá liên tục trên các mốc thời gian mới cũng giúp hệ thống đo lường được mức độ "trôi khái niệm" (concept drift) – sự suy giảm hiệu suất khi hành vi khách hàng thay đổi theo thời gian.

1.6. Trực quan hóa với Power BI

Power BI là nền tảng phân tích tình báo doanh nghiệp mạnh mẽ, cấu thành từ Power Query (xử lý dữ liệu bằng ngôn ngữ M), hệ thống mô hình hóa dữ liệu và ngôn ngữ biểu thức DAX. Trong Power BI, ngôn ngữ DAX hỗ trợ tạo ra các thước đo (measure) có khả năng tính toán linh hoạt theo ngữ cảnh của bộ lọc, cực kỳ phù hợp để xây dựng các chỉ số kinh doanh động (như tính tổng doanh thu hay tăng trưởng cùng kỳ).

Về kiến trúc kết nối, chế độ Import cho phép nạp bản sao dữ liệu vào bộ nhớ để tối ưu tốc độ tương tác, trong khi DirectQuery truy vấn trực tiếp vào cơ sở dữ liệu gốc (phù hợp với hệ thống thời gian thực). Để báo cáo đạt hiệu suất tốt nhất, Power BI nên được trỏ trực tiếp vào các View hoặc bảng kết quả đã được mô hình hóa sẵn (dạng mô hình sao) từ cơ sở dữ liệu PostgreSQL. Hệ thống báo cáo phân tích thường được thiết kế phân tầng, từ các chỉ số đo lường hiệu quả (KPI) tổng quan, biểu đồ theo dõi xu hướng, cho đến các bảng danh sách chi tiết (như danh sách cảnh báo khách hàng rời bỏ) có hỗ trợ bộ lọc và chức năng trích xuất dữ liệu.